# Tubes2A\_13515062

November 28, 2017

Tugas Besar 2 Intelijensi Buatan Prediksi Income per Tahun Website: http://predicio.herokuapp.com/ Anggota Kelompok: - Devin Alvaro / 13515062 - Stevanno Hero Leadervand / 13515082 -Rizki Ihza / 13515104 - Gianfranco Fertino Hwandiano / 13515118

## 1 Libraries

```
In [1]: import pandas as pd
    import numpy as np

from sklearn import preprocessing, neighbors, tree
    from sklearn.externals import joblib
    from sklearn.metrics import confusion_matrix
    from sklearn.model_selection import cross_val_score
    from sklearn.naive_bayes import GaussianNB
    from sklearn.neural_network import MLPClassifier

%matplotlib inline
```

#### 2 Membaca dataset

# 3 Preprocessing

#### 3.1 Feature Selection

```
for column in temp:
    le.fit(temp[column])
    temp[column] = le.transform(temp[column])

y = np.array(temp['label'])
x = np.array(temp.drop(['label'], 1))

#feature extraction
model = LogisticRegression()
rfe = RFE(model, 1)
fit = rfe.fit(x, y)
print("Feature Ranking: ")
print(fit.ranking_)
Feature Ranking:
[6 10 14 11 2 3 12 4 5 1 9 8 7 13]
```

Feature selection merupakan metode untuk memilih subset atribut-atribut/features dari dataset yang dirasa penting saja. Manfaatnya diantara lain yaitu meningkatkan akurasi model dan mempercepat proses training karena data menjadi lebih sedikit.

Metode feature selection yang kelompok kami gunakan yaitu Recursive Feature Elemination (RFE). Metode ini mengurutkan atribut-atribut (ranking) dari urutan 1 (paling penting) hingga seterusnya (semakin tidak penting).

Dari informasi di atas, dapat disimpulkan bahwa fnlwgt (atribut nomor 3 dari kiri) merupakan atribut yang paling tidak penting (urutan terakhir yaitu 14) jika dibandingkan dengan atribut-atribut lainnya. Berdasarkan hal tersebut, kami memilih untuk tidak mengikutkan atribut fnlwgt pada training model kami.

#### **Missing Value Treatment**

Dari dataset, kami melihat bahwa ada sekitar 4000 baris data yang mengandung missing value, ditandai dengan tanda?.

Kami telah melakukan berbagai eksplorasi tentang bagaimana menghandle hal tersebut.

Kami telah mencoba menghapus data yang bersangkutan dan juga mengganti value? dengan value modus ataupun rata2 dari atribut yang bersangkutan.

Namun, semua hal tersebut tidak meningkatkan akurasi dari model kami, malah justru menurunkan akurasi. Jadi, kami memutuskan untuk membiarkan value tersebut.

### 3.2 Encoding data dengan One-Hot Encoding

```
train_df = pd.get_dummies(train_df)

y = np.array(train_df['label'])
x = np.array(train_df.drop(['label'], 1))
```

### **One-Hot Encoding**

Pada dataset yang diberikan, terdapat nilai-nilai berupa string (bukan angka), sehingga harus dilakukan pemrosesan (*encoding*) agar nilai-nilai string tersebut menjadi angka yang dapat dikalkulasi oleh algoritma-algoritma *learning* menjadi model.

Untuk *preprocessing* dataset ini, kami memilih *one-hot encoding*, yaitu *preprocessing* yang mentransformasi nilai-nilai pada setiap kolom bernilai string menjadi kolomnya masing-masing. Kemudian, pada tiap kolom baru ini terdapat nilai biner (1 atau 0) yang menandakan suatu data berada dalam kategori bernilai demikian atau bukan.

Sebagai contoh, terdapat kolom Sex dengan nilai Male dan Female. Kemudian, kolom Sex ini ditransformasi menjadi 2 kolom, yaitu kolom Male dan Female. Untuk suatu data bernilai Male, maka nilai di kolom Male adalah 1 dan di kolom Female adalah 0. Berlaku pula kebalikannya untuk data bernilai Female.

Kami memilih *one-hot encoding* karena nilai-nilai berbentuk string pada dataset ini tidak tepat bila diubah menjadi angka. Misalnya saja bila pada kolom Race, nilai Asian menjadi 0, White menjadi 1, dan Black menjadi 2, menjadi tidak benar karena menandakan suatu ras bernilai lebih tinggi atau rendah dari ras lain.

One-hot encoding ini memang memiliki kelemahan yaitu menambah jumlah kolom secara signifikan sehingga meningkatkan kompleksitas algoritma *learning* yang ada, namun masih dapat ditoleransi.

## 3.3 Eksperimen untuk mendapatkan model terbaik

### 3.3.1 Naive Bayes

```
Fold-9: 0.806204
Fold-10: 0.806204
Mean: 0.801050
Accuration: 0.801050 (+/- 0.008562)
3.3.2 Decision Tree
In [8]: ID3learn = tree.DecisionTreeClassifier(criterion="entropy")
        score = cross_val_score(ID3learn, x, y, cv=10)
In [9]: for i in range(10):
            print("Fold-" + str(i + 1) + ":", "%0.6f" % score[i])
        print()
        print("Mean: %0.6f" % score.mean())
        print("Accuration: %0.6f (+/- %0.6f)" % (score.mean(), score.std() * 2))
Fold-1: 0.817931
Fold-2: 0.825553
Fold-3: 0.835381
Fold-4: 0.812654
Fold-5: 0.828317
Fold-6: 0.826781
Fold-7: 0.821560
Fold-8: 0.825246
Fold-9: 0.834152
Fold-10: 0.820639
Mean: 0.824821
Accuration: 0.824821 (+/- 0.013252)
3.3.3 k-Nearest Neighbors
In [10]: n_neighbors = 61
         KNNlearn = neighbors.KNeighborsClassifier(n_neighbors, weights='uniform')
         score = cross_val_score(KNNlearn, x, y, cv=10)
In [11]: for i in range(10):
             print("Fold-" + str(i + 1) + ":", "%0.6f" % score[i])
         print()
```

```
print("Mean: %0.6f" % score.mean())
         print("Accuration: %0.6f (+/- %0.6f)" % (score.mean(), score.std() * 2))
Fold-1: 0.842186
Fold-2: 0.847973
Fold-3: 0.852887
Fold-4: 0.841523
Fold-5: 0.838145
Fold-6: 0.853808
Fold-7: 0.843059
Fold-8: 0.851658
Fold-9: 0.851044
Fold-10: 0.854115
Mean: 0.847640
Accuration: 0.847640 (+/- 0.011201)
3.3.4 Multilayer Perceptron
In [12]: MLPlearn = MLPClassifier(solver='lbfgs',hidden_layer_sizes=(5, 2))
         score = cross_val_score(MLPlearn, x, y, cv=10)
In [13]: for i in range(10):
             print("Fold-" + str(i + 1) + ":", "%0.6f" % score[i])
         print()
         print("Mean: %0.6f" % score.mean())
         print("Accuration: %0.2f (+/- %0.6f)" % (score.mean(), score.std() * 2))
Fold-1: 0.809334
Fold-2: 0.240786
Fold-3: 0.757985
Fold-4: 0.797912
Fold-5: 0.800676
Fold-6: 0.759214
Fold-7: 0.820639
Fold-8: 0.817260
Fold-9: 0.830160
Fold-10: 0.759214
Mean: 0.739318
Accuration: 0.74 (+/- 0.336282)
```

#### Memilih model terbaik

setelah dilakukan percobaan learning dengan beberapa algoritma yaitu:

- Naive Bayes
- Decision Tree Learning
- K-Nearest neighbours
- Multilayer Perceptron

didapat model yang memiliki akurasi tertinggi untuk dataset ini adalah model K-Nearest neighbours. Oleh karena itu dipilih model K-Nearest neighbour untuk digunakan dalam perhitungan selanjutnya

### 3.4 Menyimpan model

## 3.5 Loading model

```
In [16]: KNNlearn = joblib.load('model/best.pkl')
```

# 3.6 Evaluasi dan prediksi dengan model terpilih

#### 3.6.1 Membaca test dataset

```
In [17]: test_df = pd.read_csv("data/CencusIncome.test.txt", header=None, skiprows=1)
         # name columns
         test_df = test_df.rename(columns={0: 'age', 1: 'workclass', 2: 'fnlwgt', 3: 'education'
         # remove 'fnlwqt' column
         test_df = test_df.drop(['fnlwgt'], axis=1)
         test_df.head(10)
Out[17]:
            age
                        workclass
                                      education education-num
                                                                     marital-status
         0
             38
                          Private
                                        HS-grad
                                                              9 Married-civ-spouse
         1
             28
                                                             12 Married-civ-spouse
                        Local-gov
                                     Assoc-acdm
             44
                          Private
                                   Some-college
                                                             10 Married-civ-spouse
         3
             18
                                   Some-college
                                                             10
                                                                      Never-married
         4
             34
                          Private
                                           10th
                                                              6
                                                                      Never-married
         5
             29
                                        HS-grad
                                                              9
                                                                      Never-married
             63
                 Self-emp-not-inc
                                    Prof-school
                                                             15 Married-civ-spouse
```

```
7
   24
                 Private Some-college
                                                  10
                                                           Never-married
8
   55
                 Private
                              7th-8th
                                                   4 Married-civ-spouse
9
   65
                 Private
                              HS-grad
                                                   9 Married-civ-spouse
          occupation
                      relationship
                                      race
                                              sex
                                                   capital-gain
0
     Farming-fishing
                           Husband White
                                             Male
                                                              0
1
     Protective-serv
                           Husband White
                                             Male
  Machine-op-inspct
2
                           Husband Black
                                             Male
                                                            7688
3
                          Own-child White Female
                                                              0
4
       Other-service
                     Not-in-family White
                                             Male
                                                              0
5
                         Unmarried Black
                                             Male
                                                              0
6
                           Husband White
                                             Male
                                                            3103
     Prof-specialty
7
                         Unmarried White Female
       Other-service
                                                              0
                                             Male
8
       Craft-repair
                           Husband White
                                                              0
  Machine-op-inspct
                           Husband White
                                             Male
                                                            6418
   capital-loss hours-per-week native-country label
0
             0
                             50 United-States <=50K
1
             0
                             40 United-States
                                                >50K
2
              0
                             40 United-States >50K
3
              0
                            30 United-States <=50K
4
                            30 United-States <=50K
              0
5
              0
                            40 United-States <=50K
                                               >50K
6
              0
                            32 United-States
7
             0
                            40 United-States <=50K
8
              0
                            10 United-States <=50K
9
                            40 United-States >50K
              0
```

# 3.6.2 Preprocessing test dataset

```
(16280,)
(16280, 107)
Out[19]:
                   education-num capital-gain capital-loss hours-per-week label \
             age
          0
              38
                                9
                                               0
                                                               0
                                                                                50
                                                                                         0
                               12
          1
              28
                                                0
                                                               0
                                                                                40
                                                                                         1
          2
              44
                               10
                                            7688
                                                               0
                                                                                40
                                                                                         1
          3
                               10
                                                                                30
                                                                                         0
              18
                                                0
                                                               0
          4
              34
                                6
                                                0
                                                               0
                                                                                30
                                                                                         0
          5
              29
                                9
                                                0
                                                                                40
                                                                                         0
                                                               0
          6
                               15
                                                                                32
              63
                                            3103
                                                                                         1
                                                               0
          7
              24
                               10
                                                0
                                                               0
                                                                                40
                                                                                         0
                                4
                                                0
          8
              55
                                                                0
                                                                                10
                                                                                         0
          9
              65
                                9
                                            6418
                                                               0
                                                                                40
                                                                                         1
             workclass_? workclass_Federal-gov
                                                     workclass_Local-gov
          0
                        0
                                                  0
                                                  0
          1
                        0
                                                                         1
          2
                        0
                                                  0
                                                                         0
          3
                        1
                                                  0
                                                                         0
          4
                        0
                                                  0
                                                                         0
          5
                        1
                                                  0
                                                                         0
          6
                        0
                                                  0
                                                                         0
          7
                                                  0
                        0
                                                                         0
          8
                        0
                                                  0
                                                                         0
          9
                        0
                                                  0
                                                                         0
             workclass_Never-worked
                                                                               \
          0
                                    0
          1
                                    0
          2
                                    0
          3
                                    0
          4
                                    0
          5
                                    0
          6
                                    0
          7
                                    0
          8
                                    0
          9
                                    0
```

	native-country_Puerto-Rico	native-country_Scotland	native-country_South	١
0	0	0	0	
1	0	0	0	
2	0	0	0	
3	0	0	0	
4	0	0	0	
5	0	0	0	
6	0	0	0	

```
7
                                 0
                                                               0
                                                                                          0
8
                                 0
                                                               0
                                                                                          0
9
                                 0
                                                               0
                                                                                          0
   {\tt native-country\_Taiwan} \quad {\tt native-country\_Thail} \\ {\tt and} \\
0
                           0
                                                          0
1
                           0
                                                          0
2
                           0
3
4
                           0
                                                          0
5
6
                           0
7
                           0
8
                           0
9
   native-country_Trinadad&Tobago native-country_United-States \
0
                                      0
1
                                      0
                                                                          1
2
                                      0
                                                                           1
3
                                      0
                                                                           1
4
5
6
                                      0
                                                                           1
7
                                                                           1
                                      0
8
                                      0
                                                                           1
9
                                      0
   native-country_Vietnam native-country_Yugoslavia
0
                             0
1
                                                             0
                             0
2
                                                             0
                             0
3
                                                             0
4
                             0
                                                             0
5
                             0
                                                             0
6
                             0
7
                             0
                             0
8
                                                             0
9
                             0
                                                             0
   native-country_Holand-Netherlands
0
                                          0
                                          0
1
2
                                          0
3
                                          0
                                          0
5
                                          0
6
                                          0
```

```
7 0
8 0
9 0
[10 rows x 108 columns]
```

# 3.6.3 Hasil prediksi